En primer lugar, realizamos un análisis general del contenido de los textos de la columna “post”, con el objetivo de determinar qué pasos o herramientas debemos emplear para normalizar dichos textos.

Cargamos el CSV en un Data Frame que llamaremos data.

Utilizando el comando “data.post.isna().sum()”, podemos verificar cuántos valores faltantes contiene esa columna. En este caso, será recomendable rellenar esos valores con algún contenido que indique que son “vacíos”, de manera que no interfiera en la implementación posterior. Otra observación importante es que los textos contienen tanto mayúsculas como minúsculas. Además, muchos presentan signos de puntuación (“:”), contracciones (“I’m”), stopwords, emojis, etiquetas html, saltos de línea (“/r”, “\n\n”), espacios en blanco extra, paréntesis, comillas, números, caracteres especiales (“-”), urls, implementaciones de código, tablas, entre otros.

Todos estas características las hemos identificado utilizando herramientas de pandas sobre el Data Frame o mediante una investigación detallada de algunas secciones del archivo CSV, como al notar que algunos posts contienen emojis. Tras este análisis, procedemos a implementar una función para normalizar estos posts, la función *preprocess_post*.

Por último, aclaramos que la explicación de cada uno de los pasos que se han ido siguiendo durante la implementación se encuentran en los comentarios del código.